נושאים בלמידה עמוקה - סיכום וניסיון שחזור תוצאות מאמר

An Empirical Evaluation of Generic Convolutional and Recurrent Networks for Sequence Modeling/Shaojie Bai, J. Zico Kolter, Vladlen Koltun

במאמר זה ניסו החוקרים לאתגר את האסוציאציה השכיחה בין משימות סדרתיות לבין Recurrent. החוקרים בנו רשת קונבולציונית גנרית ופשוטה יחסית, והשוו בינה לבין RNN. ESTM, RNN כמו LSTM, RNN ו CRU, במספר רב של משימות שברובן נהוג להשתמש ב Networks על כלל נגזרותיה. החוקרים קראו לרשת Residual Blocks על כלל נגזרותיה. החוקרים קראו לרשת Residual Blocks, אשר מורכבים מסדרה של קונבולוציות בקיצור TCN, והיא מורכבת מ Ropouts, מוצאות המחקר מראות כי ה TCN עלתה מורחבות, נרמול, פונקציות אקטיבציה ו dropouts. תוצאות המחקר מראות כי ה TCN עלתה בביצועים על ה Recurrent Networks, מה שגרם לחוקרים להעריך כי הזכרון של רשת ה TCN ארוך יותר מהזכרון של הרשתות שמולן היא התחרתה, ולכן יתכן כי היא נקודת פתיחה טובה יותר עבור משימות סדרתיות הדורשות זכרון רב מאשר RNN.

בפרויקט זה ניסינו לשחזר את תוצאות הניסוי של החוקרים. השווינו ב 3משימות בין רשת בפרויקט זה ניסינו לשחזר את תוצאות הניסוי של RNN ו LTSM, ובנוסף ניסינו להרחיב את TCN המורכבת מ TCNMerge אשר מחלקת את הקלט לשניים, מעבירה כל חלק ב Residual Block, מאחדת את התוצאה ומעבירה אותה ב RB נוסף. להלן תוצאות הניסוי:

TCNMerge	TCN	LSTM	RNN	
98.41%	91.21%	98.15%	91.72%	MNIST(accuracy)
-	0.02060	0.02868	0.03262	COPY TASK(loss)
8.71642	8.68761	9.33522	9.39618	MUSIC – JSB(loss)
3.70297	3.94192	4.52659	4.04973	MUSIC – Nott(loss)







